

UNIVERSITÄT
LEIPZIG

Information

Einführung in die Informatik

Leipzig, WS 26/27

Dr. Nico Willert Stark/ Prof. Dr. Ulrich Eisenecker

AGENDA



Information



Codes



Einheiten



Zahlensysteme



Informationen
Repräsentieren



Informationstheorie

INFORMATION

ASPEKTE DER INFORMATION

- Bedeutung, auch als Semantik bezeichnet – Gedanken eines Senders oder Empfängers, die mit einer Information verbunden sind, z. B. die Begrüßung einer bekannten Person
- Nachricht – eine Abfolge von Informationseinheiten, die über ein Medium übertragen werden, z. B. ein gesprochener Satz oder ein gedruckter Text, z. B. „John grüßt Paula“
- Syntax – eine Menge von Informationseinheiten sowie Kombinationsregeln, z. B. in der englischen Grammatik: Subjekt – Prädikat – Objekt
- Absender – Verfasser einer Nachricht, z. B. Ihr Professor, schreibt: „John grüßt Paula“
- Empfänger – der Empfänger einer Nachricht, z. B. du, wenn du liest oder hörst, wie dein Professor sagt: „John grüßt Paula“
- Kontext – Situation, in der die Botschaft entsteht, z. B.: John sieht Paula und grüßt sie, sobald sie ihn hören und sehen kann

INFORMATION

INFORMATIK UND INFORMATIONSTHEORIE

- Die Informatik betrachtet Informationen aus einer formalen Perspektive.
  - Informationseinheiten
  - Gruppen von Informationseinheiten
  - Informationscodes
  - Darstellung von Informationen
- Die Informationstheorie betrachtet Information ebenfalls aus formaler Sicht und konzentriert sich auf
  - Informationscodes, Entropie und Redundanz
  - Anwendungen in den Bereichen Datenkompression, Kryptografie, sichere Datenübertragung und Rekonstruktion von Informationen
  - Die Semantik wird in der Informationstheorie nicht berücksichtigt.

AGENDA



Information



Codes



Einheiten



Zahlensysteme



Informationen
Repräsentieren



Informationstheorie

There are only 10 types of people in the world: those who understand binary and those who don't

INFORMATIONSEINHEITEN

- Die kleinste Informationseinheit ist ein *bit* (**bi**nary digi**t**)
  - Entweder der Wert 0 oder 1
  - Kann beispielsweise durch eine Ladung unterhalb oder oberhalb eines bestimmten Schwellenwerts oder durch die magnetische Ausrichtung eines magnetischen Partikels dargestellt werden
- Mehr Werte darstellen → Bitgruppen
  - Nibble → Gruppe aus vier Bits
  - Byte → Gruppe von acht Bits
  - Word → bezeichnet die Anzahl der Bits, die eine CPU in einem einzigen Schritt verarbeiten kann, d. h., bei einer 16-Bit-CPU entspricht dieser Wert 16, bei einer 32-Bit-CPU 32 usw.
- Es gibt genauso viele Informationseinheiten mit einer Kardinalität größer als 2, wie es entsprechende natürliche Zahlen gibt, d. h. 3, 4, 5 usw.

INFORMATIONS CODES

- Das Grundelement eines Informationscodes ist eine Informationseinheit
  - Es kann genau ein Element aus einer Menge von Symbolen sein
    - Die Anzahl der Elemente der Symbolmenge wird als Kardinalität bezeichnet.
    - Beispielsweise ist die Symbolmenge { 0, 1 }
      - Jede Menge mit zwei Symbolen ist ein Binärcode.
      - Sie hat die Kardinalität 2
      - Eine Informationseinheit kann entweder den Wert 0 oder den Wert 1 annehmen.
    - Beispielsweise ist die Symbolmenge { a, b, c }
      - Sie hat die Kardinalität 3
      - Eine Informationseinheit kann entweder den Wert a, b oder c annehmen.
- Informationseinheiten werden gruppiert, um Werte darzustellen

INFORMATIONS CODES

FESTE LÄNGE

- Ein Informationscode, der eine feste Anzahl gruppierter Informationseinheiten zur Darstellung von Werten verwendet, wird als Informationscode mit fester Länge bezeichnet.
  - Die Anzahl der gruppierten Informationseinheiten wird als Arität bezeichnet
  - Ein Informationscode hat beispielsweise die Symbolmenge {@, #, *} und eine Arität von 2; alle möglichen unterschiedlichen Werte sind
    - @@, @#, @*
    - #@, ##, #*
    - *@, *#, **
  - Somit kann dieser Informationscode 9 verschiedene Werte darstellen

INFORMATIONS CODES

FESTE LÄNGE – EINIGE FORMELN

- Ein Informationscode mit der Kardinalität c und der Arität a kann

  $$v = c^a$$

  v verschiedene Werte darstellen
- Wenn c auf 2 beschränkt ist, d. h., wenn es sich um einen Binärcode handelt, kann er bei einer Arität von a

  $$v = 2^a$$

  v verschiedene Werte darstellen
- Bei gegebener Kardinalität c und einer Anzahl verschiedener Werte v berechnet sich die erforderliche Arität a wie folgt:

  $$a = ceil\left(\frac{\log(v)}{\log(c)}\right)$$

  - log(x) berechnet den Logarithmus von x (jede Logarithmusbasis ist zulässig)
  - Die Funktion `ceil(x)` berechnet die natürliche Zahl `y`, für die gilt: `y ≥ x`

INFORMATIONS CODES

CODE MIT VARIABLER LÄNGE

- Ein Informationscode, der eine variable Anzahl gruppierter Informationseinheiten zur Darstellung von Werten verwendet, wird als Informationscode mit variabler Länge bezeichnet.
  - Um das Ende einer Gruppe zu kennzeichnen, ist in der Regel ein spezieller Wert erforderlich
  - Beispielsweise kann der Binärcode 0 als Endmarker verwendet werden.
    - 0, 10, 110, 1110, …
  - Kann eine beliebige Anzahl von Werten darstellen
- Mehr dazu im Thema Informationstheorie

AGENDA



Information



Codes



Einheiten



Zahlensysteme



Informationen
Repräsentieren



Informationstheorie

MORE INFORMATION UNITS

BYTE-BASIERTE METRISCHE PRÄFIXE

- Ein Kilobyte (Einheitssymbol kB) entspricht 10^3 Byte = 1.000 Byte
- Ein Megabyte (Einheitssymboll *MB*) entspricht 10^3 kB = 10^6 Byte = 1,000,000 Byte
- Ein Gigabyte (Einheitssymbol *GB*) entspricht 10^3 MB
- Ein Terabyte (Einheitssymbol *TB*) entspricht 10^3 GB
- Ein Petabyte (Einheitssymbol *PB*) entspricht 10^3 TB
- Ein Exabyte (Einheitssymbol *EB*) entspricht 10^3 PB
- Ein Zettabyte (Einheitssymbol *ZB*) entspricht 10^3 EB
- Ein Yottabyte (Einheitssymbol *YB*) entspricht 10^3 ZB
- Ein Ronnabyte (Einheitssymbol RB) entspricht 10^3 YB
- Ein Quettabyte (Einheitssymbol QB) entspricht 10^3 RB

MORE INFORMATION UNITS

BIT-BASIERTE METRISCHE PRÄFIXE

- Ein kilobit (Einheitssymbol *kbit*) entspricht 10^3 bit = 1,000 bit
- Ein megabit (Einheitssymbol *Mbit*) entspricht 10^3 kbit = 10^6 bit = 1,000,000 bit
- Ein gigabit (Einheitssymbol *Gbit*) entspricht 10^3 Mbit
- Ein terabit (Einheitssymbol *Tbit*) entspricht 10^3 Gbit
- Ein petabit (Einheitssymbol *Pbit*) entspricht 10^3 Tbit
- Ein exabit (Einheitssymbol *Ebit*) entspricht 10^3 Pbit
- Ein zettabit (Einheitssymbol *Zbit*) entspricht 10^3 Ebit
- Ein yottabit (Einheitssymbol *Ybit*) entspricht 10^3 Zbit
- Ein ronnabit (Einheitssymbol Rbit) entspricht 10^3 Ybit
- Ein quettabit (Einheitssymbol Qbit) entspricht 10^3 Rbit

MORE INFORMATION UNITS

BYTE-BASIERTE BINÄRPRÄFIXE

- Ein kibibyte (Einheitssymbol *KiB*) entspricht 2^{10} Byte = 1,024 Byte
- Ein mebibyte (Einheitssymbol *MiB*) entspricht 2^{10} KiB = 2^{20} Byte = 1,048,576 Byte
- Ein gibibyte (Einheitssymbol *GiB*) entspricht 2^{10} MiB
- Ein tebibyte (Einheitssymbol *TiB*) entspricht 2^{10} GiB
- Ein pebiyte (Einheitssymbol *PiB*) entspricht 2^{10} TiB
- Ein exbibyte (Einheitssymbol *EiB*) entspricht 2^{10} PiB
- Ein zebibyte (Einheitssymbol *ZiB*) entspricht 2^{10} EiB
- Ein yobibyte (Einheitssymbol *YiB*) entspricht 2^{10} ZiB

MORE INFORMATION UNITS

BIT-BASIERTE BINÄRPRÄFIXE

- Ein kibibit (Einheitssymbol *Kibit*) entspricht 2^{10} bit = 1,024 bit
- Ein mebibit (Einheitssymbol *Mibit*) entspricht 2^{10} Kibit = 2^{20} bit = 1,048,576 bit
- Ein gibibit (Einheitssymbol *Gibit*) entspricht 2^{10} Mibit
- Ein tebibit (Einheitssymbol *Tibit*) entspricht 2^{10} Gibit
- Ein pebibit (Einheitssymbol *Pibit*) entspricht 2^{10} Tibit
- Ein exbibit (Einheitssymbol *Eibit*) entspricht 2^{10} Pibit
- Ein zebibit (Einheitssymbol *Zibit*) entspricht 2^{10} Eibit
- Ein yobibit (Einheitssymbol *Yibit*) entspricht 2^{10} Zibit

BINÄRE VS. METRISCHE MAßEINHEITEN

WICHTIG ZU WISSEN

- Lange Zeit wurden Informationseinheiten zur Basis 2 (= 1,024 Byte) verwendet, jedoch mit Bezeichnungen zur Basis 10 (= 1,000 Byte), d. h.,
  - 1 KB = 1.024 Byte
  - 1 MB = 1,024 KB = 1,024 · 1,024 bytes = 2^{20} bytes
  - 1 GB = 1,024 MB = 1,024 · 1,024 · 1,024 =2^{30} bytes
  - …
- Viele Normungsgremien, z. B. IEC, IEEE, ISO und NIST, haben diese Verwendung als veraltet eingestuft und sich, wie zuvor beschrieben, für binäre und metrische Präfixe entschieden.
  - Dennoch werden die Bezeichnungen der metrischen Präfix-Informationseinheiten weiterhin im Sinne der binären Präfix-Informationseinheiten verwendet.

BINÄRE VS. METRISCHE MAßEINHEITEN

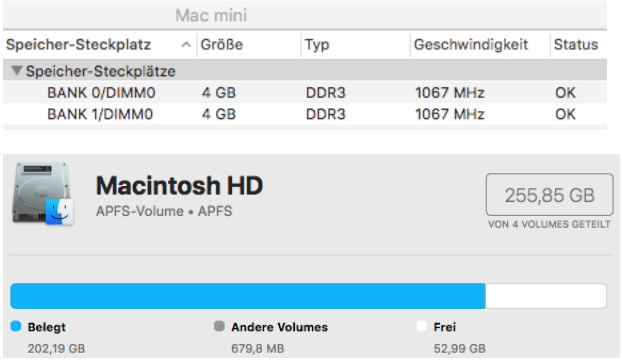
EINIGE BEISPIELE

- Die Speicherkapazität von RAM-Modulen wird meist in GB mit einem binären Präfix angegeben, d. h.,
  4 GB RAM = 4 **x** 1,024 MB
  = 4 **x** 1,024 **x** 1,024 KB = 4 **x** 1,024 **x** 1,024 **x** 1,024 bytes
  = 4,294,967,296 bytes
- Anbieter geben die Kapazität von Massenspeichern, z. B. Festplatten, SSDs, CDs, DVDs und BRs, in der Regel unter Verwendung von dezimalen Präfixen an, die genau diese Bedeutung haben, d. h., 1 TB = 1.000 GB
- Betriebssysteme wenden unterschiedliche Richtlinien an, um die Größe des Arbeitsspeichers und des Massenspeichers anzugeben.

BINÄRE VS. METRISCHE MAßEINHEITEN

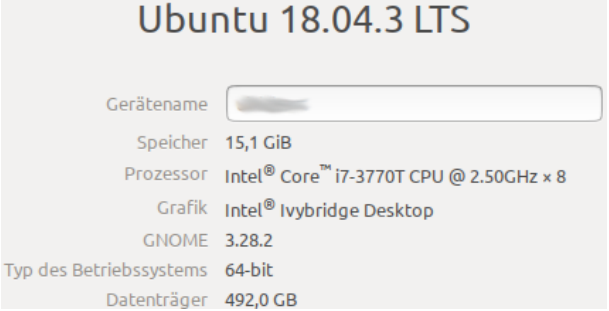
UNTERSCHIEDE NACH BETRIEBSSYSTEME

macOS High Sierra
8 GiB RAM, 244 GiB SSD



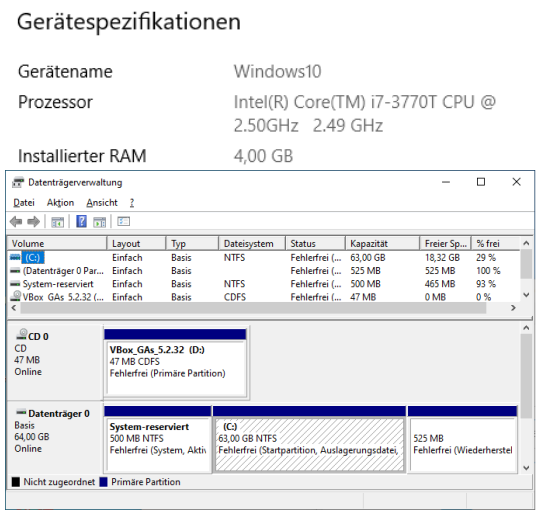
Uneinheitliche Verwendung von GB

Ubuntu 18.04.3 LTS
16 GiB RAM, 465,66 GiB SSD (GPartED)
488,28125 (internet info)



Möglicherweise fehlerhafte Berechnungen im Ubuntu-Infodialog

Windows 10
4 GiB RAM, 64 GiB SSD
(VirtualBox settings)



Durchgängige Verwendung von „GB“ im Sinne von „GiB“

Screenshots by Prof. Eisenecker

AGENDA



Information



Codes



Einheiten



Zahlensysteme



Informationen
Repräsentieren



Informationstheorie

ZAHLENSYSTEME

- Ein Zahlensystem stellt Zahlen dar
  - Basierend auf Ziffernsymbolen, auch als Ziffern bezeichnet
- Zwei Kategorien von Zahlensystemen zur Darstellung natürlicher Zahlen
  - *Additionssystem* Sign-value notation)
    - Der Wert einer Zahl wird berechnet, indem die Werte der Ziffern (nach bestimmten Regeln) addiert (oder subtrahiert) werden, z. B. bei Strichlisten oder im römischen Zahlensystem.
  - *Positionssystem* or *Stellenwertsystem* (Positional notation / place-value notation)
    - Der Wert einer Zahl wird anhand des Werts jeder Ziffer und ihrer Position berechnet, z. B. im Dezimalsystem

POSITIONSSYSTEM

- In einem Positionssystem ist es offensichtlich, welche der beiden Zahlen die größere ist.
  - Unterschiedliche Anzahl von Positionen: Die Zahl mit den meisten Positionen
  - Gleiche Anzahl von Stellen: Die Zahl, bei der – von links nach rechts – zum ersten Mal eine Ziffer mit einem größeren Wert auftritt
- Ein Positionssystem besteht aus
  - Eine geordnete Folge von Ziffern, d. h. Ziffernsymbole
  - Ein Algorithmus, der für eine gegebene Zahl diese Zahl plus eins erzeugt

POSITIONSSYSTEM

BEISPIEL → BINÄRES POSITIONSSYSTEM

- Geordnete Folge von Ziffernsymbolen: (0, 1)
  - 0 ist die erste Ziffer mit dem Wert 0
  - 1 ist die letzte Ziffer mit dem Wert 1
- Algorithmus zur Erzeugung der Zahl plus Eins
  1. Beginnen Sie mit der Ziffer ganz rechts
  2. Wenn die aktuelle Ziffer nicht die letzte Ziffer der Folge ist, ersetze die aktuelle Ziffer durch ihre Nachfolgende → Fertig!
  3. Andernfalls ersetze die aktuelle Ziffer durch die erste Ziffer der Folge und wähle die Ziffer unmittelbar links von der aktuellen Ziffer als neue aktuelle Ziffer aus → Fahre mit 2 fort.
     - Wenn von der aktuellen Ziffer keine Ziffer mehr übrig ist, gehe davon aus, dass es sich um die erste Ziffer der Folge handelt.

POSITIONSSYSTEM

KARDINALITÄT

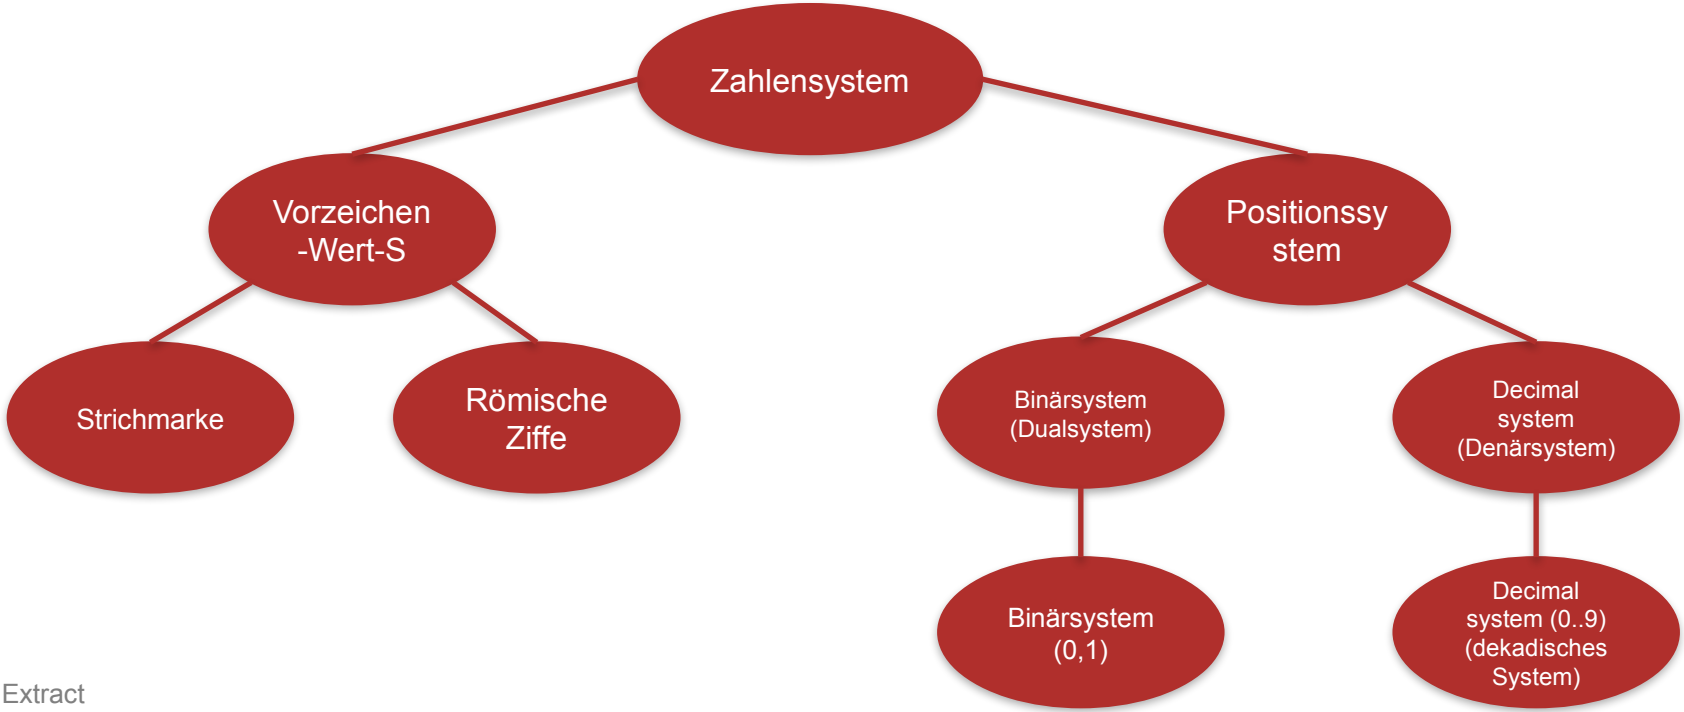
- Die Anzahl der Ziffern einer Ziffernfolge in einem Positionssystem wird als Kardinalität bezeichnet.
  - Die Anzahl der gruppierten Informationseinheiten eines Informationscodes wird auch als Kardinalität bezeichnet.
- Positionssysteme mit der Kardinalität 2 werden als binäre Systeme oder Dualsysteme bezeichnet.
  - (F, W), (a, b) sind Dualsysteme
  - (0, 1) ist ebenfalls ein Dualsystem nur speziell als Binärsystem bezeichnet
- Positionssysteme mit der Kardinalität 10 werden als Dezimalsysteme bezeichnet.
  - (a, b, c, d, e, f, g, h, i, j) ist ein Dezimalsystem
  - (0, 1, 2, 3, 4, 5, 6, 7, 8, 9) ist ebenfalls ein Dezimalsystem aber speziell ein *dekadisches System*

ZAHLEN IN POSITIONSSYSTEMEN

BEIPSPIEL MIT (@, 3, x), (0, 1, 2), UND (0, 1, 2, 3, 4, 5, 6, 7, 8, 9)

@	3	x	3@	33	3x	x@	x3	xx	3@@	3@3	3@x	33@	333	33x
0	1	2	10	11	12	20	21	22	100	101	102	110	111	112
0	1	2	3	4	5	6	7	8	9	10	11	12	13	14

TAXONOMIE DER ZAHLENSYSTEME



Extract

AGENDA



Information



Codes



Einheiten



Zahlensysteme



Informationen Repräsentieren



Informationstheorie

DARSTELLUNG VON INFORMATIONEN

NATÜRLICHE ZAHLEN

- Die Menge der natürlichen Zahlen N umfasst alle positiven ganzen Zahlen, beginnend mit Null.
  - N = { 0, 1, 2 … ∞ }
  - N ist abzählbar unendlich
- In einem Computer werden natürliche Zahlen in der Regel mit einer festen und geraden Anzahl von Bytes b dargestellt, z. B. 1, 2, 4, 6, 8 …
  - Daher kann nur eine endliche Teilmenge von N dargestellt werden: Ns = {l .. u }
    - In der Regel wird die Untergrenze l auf 0 gesetzt.
    - Somit berechnet sich die Obergrenze u wie folgt: $u = 2^{b \times 8} - 1$
      - Z. B. für zwei Byte große natürliche Zahlen $u = \left(2^{2 \times 8} - 1\right) = 2^{16} - 1 = 65{,}535$

DARSTELLUNG VON INFORMATIONEN

NATÜRLICHE ZAHLEN

- In einem Computer wird eine natürliche Zahl in binärer Form gespeichert.
  - Das Bit ganz rechts ist das sogenannte niedrigstwertige Bit (least significant bit LSB)
    - Stellt die niedrigste Ziffer der Binärzahl dar
  - Das Bit ganz links ist das sogenannte höchstwertige Bit (most significant bit MSB)
    - Die höchste Ziffer der Binärzahl
  - Die einzelnen Bits einer Binärzahl mit n Bits werden von der Position 0 (die dem LSB entspricht) bis zur Position n – 1 (die dem MSB entspricht) gezählt.

Binärzahl	1	1	0	1	0	0	1	1
Position	7	6	5	4	3	2	1	0
	MSB							LSB

DARSTELLUNG VON INFORMATIONEN

VORZEICHENLOSE BINÄRZAHLEN

MSB LSB

00000000_2 =	0_{10}	00001001_2 =	9_{10}	00010010_2 =	18_{10}
00000001_2 =	1_{10}	00001010_2 =	10_{10}	00010011_2 =	19_{10}
00000010_2 =	2_{10}	00001011_2 =	11_{10}	00010100_2 =	20_{10}
00000011_2 =	3_{10}	00001100_2 =	12_{10}	00010101_2 =	21_{10}
00000100_2 =	4_{10}	00001101_2 =	13_{10}	00010110_2 =	22_{10}
00000101_2 =	5_{10}	00001110_2 =	14_{10}	00010111_2 =	23_{10}
00000110_2 =	6_{10}	00001111_2 =	15_{10}	…	
00000111_2 =	7_{10}	00010000_2 =	16_{10}	11111110_2 =	254_{10}
00001000_2 =	8_{10}	00010001_2 =	17_{10}	11111111_2 =	255_{10}

DARSTELLUNG VON INFORMATIONEN

BERECHNUNG DES DEZIMALWERTS EINER BINÄRZAHL

- Das Binärsystem und das Dezimalsystem sind Positionssysteme.
  - Die allgemeine Formel zur Berechnung des Dezimalwerts v einer Zahl mit n Ziffern in einem Positionssystem mit der Basis b lautet (di ist der Wert der Ziffer an der Position i)

$$v = \sum_{n-1}^{i=0} d_i \times b^i$$

  - Für ein binäres System lautet die spezielle Formel (b wird zu 2)

$$v = \sum_{n-1}^{i=0} d_i \times 2^i$$

Bsp., $10010111_2 = 1\times2^0 + 1\times2^1 + 1\times2^2 + 0\times2^3 + 1\times2^4 + 0\times2^5 + 0\times2^6 + 1\times2^7$

$= 1 + 2 + 4 + 0 + 16 + 0 + 0 + 128 = 151$

DARSTELLUNG VON INFORMATIONEN

ADDITION UND MULTIPLIKATION VON BINÄRZAHLEN

+	0	1
0	0	1
1	1	10

```
  01101001
+ 00111101
  1111   1 carry-over
= 10100110
```

*	0	1
0	0	0
1	0	1

```
  01101001 * 00111101
  00000000
+  00000000
+   01101001
+    01101001
+     01101001
+      01101001
+       00000000
+        01101001
    110101011     carry over
     1 1 1        carry over
=   1100100000101
```

DARSTELLUNG VON INFORMATIONEN

GANZZAHLEN / INTEGRALZAHLEN

- Menge der ganzen Zahlen Z umfasst alle ganzen Zahlen einschließlich der Null.
  - Z = { -∞, …, -2, -1, 0, 1, 2 … ∞ }
  - Z ist abzählbar unendlich
- Ganzzahlen werden in Computern wie natürliche Zahlen dargestellt
  - Es kann nur eine endliche Teilmenge von Z dargestellt werden, Z_s = {l .. u}
    - In der Regel wird die Untergrenze l auf $l = -\frac{2^{b \times 8}}{2}$
    - Dementsprechend lautet die Obergrenze u $u = \frac{2^{b \times 8}}{2} - 1$

$$l = -\frac{2^{2 \times 8}}{2} = -32.768$$

  - Eine vorzeichenbehaftete digitale 2-Byte-Zahl hat die Grenzen:

$$u = \frac{2^{2 \times 8}}{2} - 1 = 32.767$$

DARSTELLUNG VON INFORMATIONEN

VORZEICHENBEHAFTETE BINÄRZAHLEN

- Eine ganze Zahl wird in binärer Form gespeichert, in der Regel im Zweierkomplement.
  - Anhand der Bits lässt sich nicht feststellen, ob eine Binärzahl vorzeichenbehaftet ist oder nicht.
  - Ist bekannt, dass es sich um eine vorzeichenbehaftete Binärzahl handelt, ist die Zahl negativ, wenn ihr höchstwertiges Bit gesetzt ist

0000_2 =	0_{10}	0100_2 =	4_{10}	1000_2 =	-8_{10}	1100_2 =	-4_{10}
0001_2 =	1_{10}	0101_2 =	5_{10}	1001_2 =	-7_{10}	1101_2 =	-3_{10}
0010_2 =	2_{10}	0110_2 =	6_{10}	1010_2 =	-6_{10}	1110_2 =	-2_{10}
0011_2 =	3_{10}	0111_2 =	7_{10}	1011_2 =	-5_{10}	1111_2 =	-1_{10}

MSB LSB

DARSTELLUNG VON INFORMATIONEN

BERECHNUNG DES DEZIMALWERTS EINER VORZEICHENBEHAFTETEN BINÄRZAHL

- Ist das MSB einer vorzeichenbehafteten Binärzahl nicht gesetzt, gilt dieselbe Formel wie für dezimale Werte von vorzeichenlosen Binärzahlen.

$$v = \sum_{n-1}^{i=0} d_i \times 2^i$$

- Wenn das MSB gesetzt ist, muss die folgende Formel angewendet werden

$$v = -\left\{2^n - \sum_{n-1}^{i=0} d_i \times 2^i\right\}$$

E.g., $10011011_2 = -\left(2^8 - \left(1\times2^0 + 1\times2^1 + 1\times2^3 + 1\times2^4 + 1\times2^7\right)\right) = -\left(256 - 155\right) = -101$

DARSTELLUNG VON INFORMATIONEN

ALTERNATIVE BERECHNUNG DES DEZIMALWERTS EINER VORZEICHENBEHAFTETEN BINÄRZAHL

- Ist das MSB einer vorzeichenbehafteten Binärzahl gesetzt, gibt es eine alternative Möglichkeit, ihren Dezimalwert zu berechnen
  1. Bitweise Negation der Binärzahl, z. B. 10011011 → 01100100
  2. Addiere 1 zur negierten Binärzahl, z. B. 01100100 + 1 → 01100101
  3. Berechne den Dezimalwert der resultierenden Zahl, z. B. 1 + 4 + 32 + 64 = 101
  4. Das Vorzeichen der berechneten Dezimalzahl umkehren, z. B., -101

BINÄRZAHLEN ZU ANDEREN SYSTEMEN

DARSTELLUNG ALS OKTAL- UND HEXADEZIMALZAHL

- Für Menschen ist die Arbeit mit (langen) Binärzahlen mühsam und fehleranfällig.
  - Oktalzahlen bestehen aus den Ziffern (0, 1, 2, 3, 4, 5, 6, 7)
    - In der Programmierung wird einer Oktalzahl eine 0 vorangestellt.
    - Alternativ kann der Index 8 angehängt werden
    - E.g., 077 = 77_8 = 63_{10}
  - Hexadezimalzahlen bestehen aus den Ziffern (0, 1, 2, 3, 4, 5, 6, 7, 8, 9, A, B, C, D, E, F)
    - In der Programmierung wird einer Hexadezimalzahl das Präfix „0x“ vorangestellt.
    - Alternativ kann der Index 16 angehängt werden
    - E.g., 0x10FF = $10FF_{16}$ = 4351_{10}

BINÄRZAHLEN ZU ANDEREN SYSTEMEN

DARSTELLUNG ALS OKTAL- UND HEXADEZIMALZAHL

- Eine Binärzahl lässt sich mithilfe von 3-Bit-Gruppen in eine Oktalzahl umwandeln.
  - $000\ 000_2$ = $0\ 0_8$
  - $000\ 001_2$ = $0\ 1_8$
  - ...
  - $111\ 110_2$ = $7\ 6_8$
  - $111\ 111_2$ = $7\ 7_8$
- Eine Binärzahl lässt sich mithilfe von 4-Bit-Gruppen in eine Hexadezimalzahl umwandeln.
  - $0000\ 0000_2$ = $0\ 0_{16}$
  - $0000\ 0001_2$ = $0\ 1_{16}$
  - ...
  - $1111\ 1110_2$ = $F\ E_{16}$
  - $1111\ 1111_2$ = $F\ F_{16}$

UMWANDLUNG VON DEZIMALZAHLEN IN BINÄRZAHLEN

- Zwei Methoden zur Umwandlung einer Dezimalzahl in eine Zahl eines beliebigen anderen Positionssystems, einschließlich des Binärsystems
  - *Potenzmethode*
  - *Divisions-Rest-Methode*
- Beide Verfahren eignen sich gut für die Umwandlung von Dezimalzahlen in Binärzahlen.

UMWANDLUNG VON DEZIMALZAHLEN IN BINÄRZAHLEN

POTENZMETHODE

- d ist die Dezimalzahl, a die Arität des Zielpositionssystems

1. Finde die Zahl n, für die Folgendes gilt: $a^n \leq d \wedge a^{n+1} > d$
2. *d* wird ganzzahlig durch a^n geteilt, das Ergebnis nennen wir *q*
3. Wenn n gleich 0 ist, gehe zu 6.
4. Der neue Wert von d beträgt $d - q^n$
5. Der neue Wert von n ist der Wert von n – 1; gehe zu 2.
6. Die Quotienten q ergeben die gesuchte Zahl; der erste Quotient ist die Position mit dem höchsten Wert

$$n = floor\left(\frac{\log(d)}{\log(a)}\right)$$

- log(x) berechnet den Logarithmus von x (jede Logarithmusbasis ist zulässig)
- Die Funktion floor(x) berechnet die natürliche Zahl y, für die gilt: y ≤ x

UMWANDLUNG VON DEZIMALZAHLEN IN BINÄRZAHLEN

BEISPIELHAFTE BERECHNUNG UNTER VERWENDUNG DER POTENZMETHODE

– $76_{10} = ?_2$

$2^6 = 64 (\leq 76)$ und $2^7 = 128 (> 76)$

$76 \div 2^6 = 1$	$76 - 1 \times 2^6 = 12$
$12 \div 2^5 = 0$	$12 - 0 \times 2^5 = 12$
$12 \div 2^4 = 0$	$12 - 0 \times 2^4 = 12$
$12 \div 2^3 = 1$	$12 - 1 \times 2^3 = 4$
$4 \div 2^2 = 1$	$4 - 1 \times 2^2 = 0$
$0 \div 2^1 = 0$	$0 - 0 \times 2^1 = 0$
$0 \div 2^0 = 0$	

$76_{10} = 1001100_2$

UMWANDLUNG VON DEZIMALZAHLEN IN BINÄRZAHLEN

DIVISIONS-REST-METHODE

- d ist die Dezimalzahl, a die Arität des Zielpositionssystems
  1. d wird durch a ganzzahlig geteilt, das Ergebnis wird in q gespeichert und der Rest wird notiert
  2. Wenn q gleich 0 ist, gehe zu 4.
  3. Der neue Wert von d ist q, gehe zu 1
  4. Die erfassten Reste ergeben die gesuchte Zahl; der zuletzt erfasste Rest ist die Stelle mit dem höchsten Wert

UMWANDLUNG VON DEZIMALZAHLEN IN BINÄRZAHLEN

UMGANG MIT RESTEN – BEISPIELRECHNUNG

- $76_{10} = ?_2$

  76 ÷ 2 = 38 remainder 0
  38 ÷ 2 = 19 remainder 0
  19 ÷ 2 = 9 remainder 1
  9 ÷ 2 = 4 remainder 1
  4 ÷ 2 = 2 remainder 0
  2 ÷ 2 = 1 remainder 0
  1 ÷ 2 = 0 remainder 1

  $76_{10} = 1001100_2$





DARSTELLUNG VON INFORMATIONEN

LITTLE ENDIAN VS. BIG ENDIAN

- Binärzahlen mit 2, 4 oder mehr Bytes können unterschiedlich gespeichert werden,
- Für den Datenaustausch ist möglicherweise eine Konvertierung erforderlich!
  - Big endian
    - Das Byte mit dem höheren Wert steht vor dem Byte mit dem niedrigeren Wert (von links nach rechts)
    - Unix-systeme und ältere CPUs
  - Little endian
    - Das Byte mit dem niedrigeren Wert steht vor dem Byte mit dem höheren Wert (von links nach rechts)
    - Intel und kompatible CPUs
  - $00111100\ 11000011_2 = 15555_{10}$ →

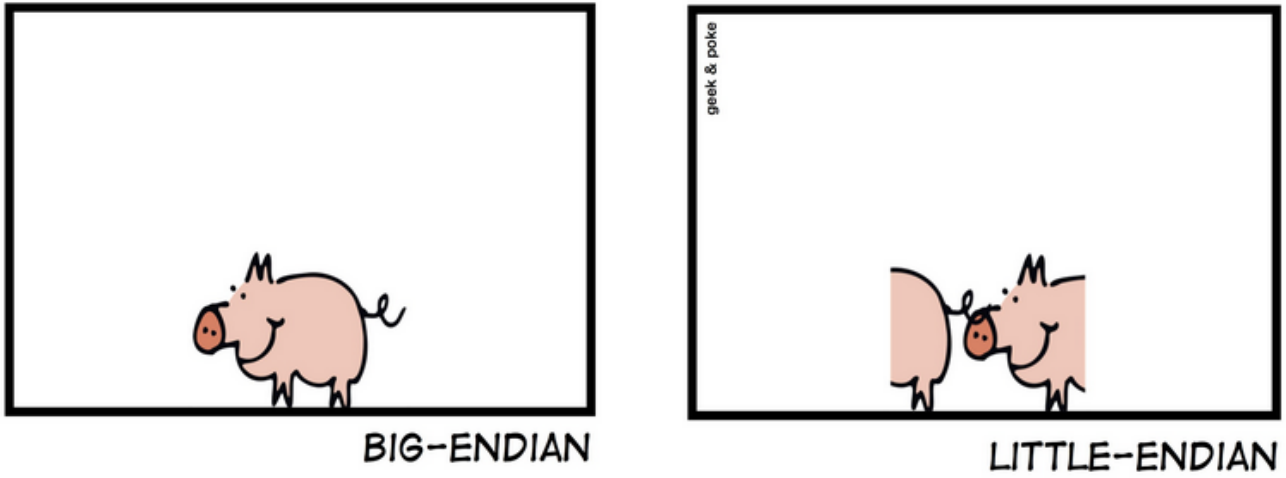
Big endian		→	Little endian	
addr. 00	addr. 01		addr. 00	addr. 01
00111100	11000011	→	11000011	00111100

DARSTELLUNG VON INFORMATIONEN

LITTLE ENDIAN VS. BIG ENDIAN

Big endian
addr. 00 addr. 01
00111100 11000011

Little endian
addr. 00 addr. 01
11000011 00111100



https://geekandpoke.typepad.com/geekandpoke/2011/09/simply-explained-1.html

DARSTELLUNG VON INFORMATIONEN

ZEICHEN UND ZEICHENFOLGEN - CHARACTERS AND STRINGS

- Ein Zeichen wird durch eine feste Anzahl von Bytes dargestellt, in der Regel ein Byte oder ein Vielfaches davon.
- Zeichencodes legen fest, welches Bitmuster welchem Zeichen entspricht
  - Bekannte Zeichencodes sind
    - ASCII (American Standard Code for Information Interchange code)
    - Unicode
- Die Darstellung einer Zeichenkette (Zeichenfolge) basiert auf Zeichen und Zeichencodes, unterscheidet sich jedoch in folgenden Punkten:
  - Feste vs. variable Länge
  - Verwendung von Zähl-Bytes oder speziellen Bytes zum Markieren des String-Endes

DARSTELLUNG VON INFORMATIONEN

ASCII

- Ursprünglich war ASCII ein 7-Bit-Code, später wurden alle 8 Bit eines Bytes genutzt (Extended ASCII)
  - 0 .. 31: nicht druckbare Zeichen, d. h. Steuercodes, z. B. Zeilenumbruch
  - 32 .. 47, 58 .. 64, 91 .. 96, 123 .. 127: Sonderzeichen, z. B. Leerzeichen, „!“
  - 48 .. 57: Arabische Ziffern, i.e., ‘0’.. ‘9’
  - 65 .. 90: Großbuchstaben, i.e., ‘A’..’Z’
  - 97 .. 122: Kleinbuchstaben, i.e., ‘a’..’z’
  - 128 .. 255: Länderspezifische Sonderzeichen und halbgrafische Zeichen, e.g. „Ä“
- In der Regel werden Zeichenfolgen anhand der ASCII-Werte ihrer Zeichen sortiert, d. h. „AB“ steht in aufsteigender Reihenfolge vor „Ab“.

DARSTELLUNG VON INFORMATIONEN

UNICODE

- ASCII und verwandte Zeichencodes können nicht alle Zeichen nationaler Alphabete abdecken
- Unicode, ursprünglich ein 16-Bit-Code mit 65.536 verschiedenen Zeichen, ist ein Standard der Computerindustrie, um dieses Defizit zu beheben
  - Die aktuellste Version (16, siehe „Unicode“) umfasst 154.998 Zeichen sowie 168 Sammlungen weiterer Sonderzeichen.
  - Es kann mit verschiedenen Zeichenkodierungen implementiert werden, z. B. UTF-8
    - Es verwendet ein Byte zur Darstellung der ersten 128 Unicode-Codepunkte und maximal vier weitere Bytes für andere Zeichen.
    - Somit ist ein 7-Bit-ASCII-Text auch ein UTF-8-Text.

DARSTELLUNG VON INFORMATIONEN

FLIEßKOMMAZAHLEN / GLEITKOMMAZAHLEN

- Aufgrund des begrenzten Speichers stellen Gleitkommazahlen reelle Zahlen annähernd dar, wobei eine feste Anzahl von Bytes verwendet wird, z. B. 4, 8 oder 12 Bytes, die in konstanter Zeit verarbeitet werden.
- Die Zahl 123.456 als Fließkommazahl entspricht 1.23456×10^{2}
  - Der Wertebereich und die Genauigkeit einer
  - Gleitkommazahl hängen von der Größe des Mantissens und des Exponenten ab
  - Irrationale Zahlen und rationale Zahlen, die mehr Ziffern (ohne nachgestellte Nullen) haben als der Mantissenteil, können nicht dargestellt werden.

exponent
Significand (in German *Mantisse*)
base

- Die Gleitkommaarithmetik **kann nicht als exakt** angesehen werden und führt manchmal zu falschen Ergebnissen.

GLEITKOMMA → BINÄR & UNGENAUIGKEITEN

- 12.375
  - 12 = 1100 (zb. mit Restmethode – 12:2 = 0 , 6:2 = 0, 3:2 = 1, 1:2 = 1)
  - Nach dem Komma → Multiplikation mit der Arität e.g. 2 und notiert die Zahl vorm resultierenden Komma ab und schneidet diese ab
    - 0.375 * 2 = 0.75 → 0 gemerkt
    - 0.75 * 2 = 1.5 → 1
    - 0.5 * 2 = 1.0 → 1
    - == 011
  - 12.375 = 1100.011 → wird im System noch in Normalform gebracht.
- 0.2
  - 0.2 * 2 = 0.4; 0.4 * 2 = 0.8; 0.8 * 2 = 1.6; 0.6 * 2 = 1.2; 0.2 *2 = 0.4 …..
  - 0.001100110011…..

AGENDA



Information



Codes



Einheiten



Zahlensysteme



Informationen
Repräsentieren



Informationstheorie

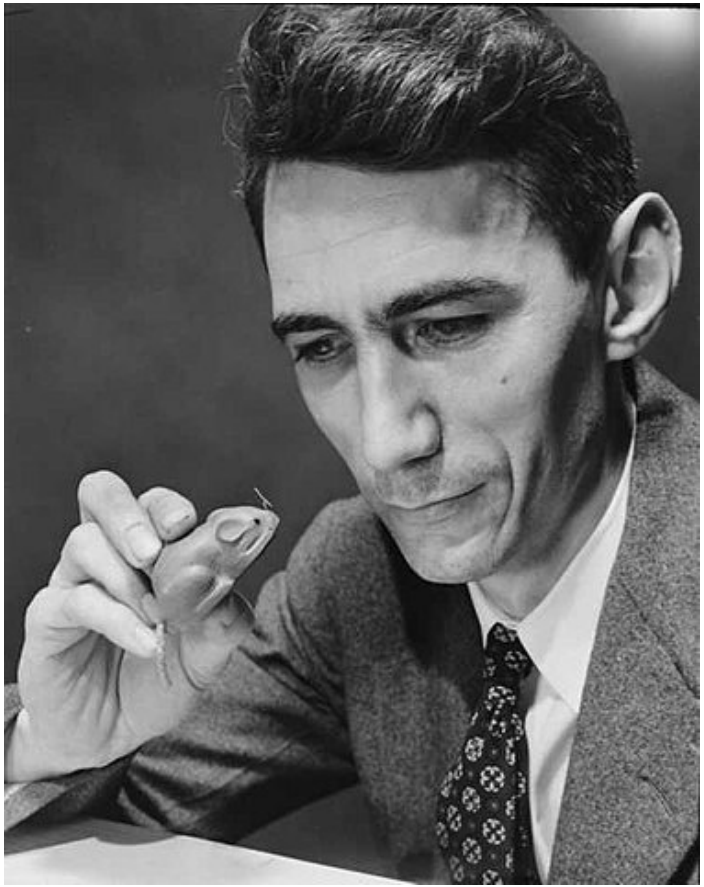
INFORMATIONSCODES

VARIABLE LÄNGE

- Ein Informationscode, der eine variable Anzahl gruppierter Informationseinheiten zur Darstellung von Werten verwendet
  - Informationscode mit variabler Länge
- Binäre Informationscodes variabler Länge sind in der Informationstheorie von entscheidender Bedeutung.
- Binäre Informationscodes zielen darauf ab, die darzustellenden Informationen möglichst kompakt, d. h. mit möglichst geringer Redundanz, zu kodieren.
  - Häufig vorkommende Informationsabschnitte werden mit kürzeren Bitfolgen kodiert, während selten vorkommende Informationsabschnitte mit längeren Bitfolgen kodiert werden.

INFORMATIONSTHEORIE

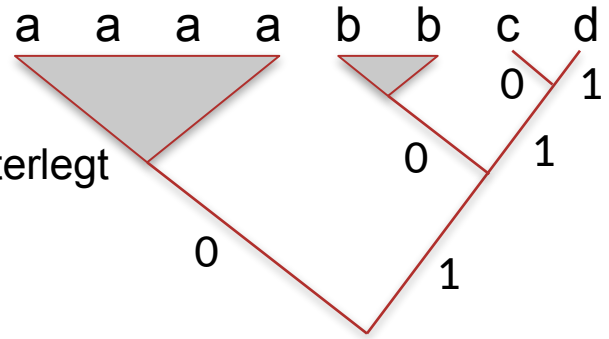
- In der Informationstheorie geht es um Information und deren Zusammenhang mit
  - Entropie, d. h. Unordnung
  - Redundanz, d. h. (überflüssige) Wiederholung
- Anwendungsbereiche sind
  - Fehlererkennung und -korrektur
  - Datenkomprimierung
  - Kryptografie
  - Blockchain und andere Technologien



Claude Shannon (1916 – 2001), founder of information theory as scientific discipline
(DobriZheglov - Own work, CC BY-SA 4.0, https://commons.wikimedia.org/w/index.php?curid=48459872)

CODE-BAUM

- Zu verschlüsselnder Text: aaaabbcd
- Codebaum (Shannon-Fano-Codierung*))
  - Nicht erforderliche Entscheidungen sind grau hinterlegt
  - Ergebnis der Kodierung
    - a → 0
    - b → 10
    - c → 110
    - d → 111
  - Kodierter Text: 00001010110111
    - Bei der Dekodierung von links nach rechts gibt es keine Mehrdeutigkeiten.



*) Es gibt Alternativen zur Shannon-Fano-Kodierung, z. B. den Huffman-Code, die weniger redundante Kodierungen erzeugen.

EINIGE GRUNDLEGENDE KONZEPTE DER INFORMATIONSTHEORIE

ABSOLUTE UND RELATIVE HÄUFIGKEIT

- Absolute Häufigkeit *F* eines Symbols *S*, F_S: Anzahl der Vorkommen von S
- Relative Häufigkeit f eines Symbols S:
  - N ist die Anzahl aller Vorkommen aller Symbole
  - In „aaaabbcd“ lauten die relativen Häufigkeiten
    - $f_a = \frac{4}{8} = \frac{1}{2} = 2^{-1}$
    - $f_b = \frac{2}{8} = \frac{1}{4} = 2^{-2}$
    - $f_c = \frac{1}{8} = 2^{-3}$
    - $f_d = \frac{1}{8} = 2^{-3}$

EINIGE GRUNDLEGENDE KONZEPTE DER INFORMATIONSTHEORIE

NORMIERTER INFORMATIONSWERT UND INFORMATIONSANTEIL EINES SYMBOLS

- *Informationsbetrag h* eines Symbols *S* ist definiert als – $h_S = ld\left(\frac{1}{f_S}\right)$,

  Bsp. Der Symbole im Text "*aaaabbcd*"

$$h_a = ld\left(\frac{1}{0.5}\right) = 1, h_b = ld\left(\frac{1}{0.25}\right) = 2,\ h_c = ld\left(\frac{1}{0.125}\right) = 3,\ hI_d = ld\left(\frac{1}{0.125}\right) = 3$$

- *Informationsbeitrag A* eines Symbols *S* ist definiert als

$$A_S = N \times f_S \times ld\left(\frac{1}{f_S}\right) = F_S \times ld\left(\frac{1}{f_S}\right)$$

  Bsp. Der Symbole im Text "*aaaabbcd*"

  - $A_a = 4 \times ld\left(\frac{1}{0.5}\right) = 4,\ A_b = 2 \times ld\left(\frac{1}{0.25}\right) = 4,$
    $A_c = 1 \times ld\left(\frac{1}{0.125}\right) = 3,\ A_D = 1 \times ld\left(\frac{1}{0.125}\right) = 3$

EINIGE GRUNDLEGENDE KONZEPTE DER INFORMATIONSTHEORIE

GESAMTINFORMATION EINES TEXTES UND DURCHSCHNITTLICHE INFORMATION EINES SYMBOLS

- *Gesamtinformation T* eines Textes t ist definiert als (S steht für Symbol, N für die Anzahl der Symbole des Textes)

$$T_t = \sum_{S=1}^{n} N \times f_S \times ld\left(\frac{1}{f_S}\right), \text{given that } \sum_{S=1}^{n} f_S = 1$$

E.g., $T_{aaabbcd} = 14\,bit$

- *durchschnittliche Information H* eines Symbols S ist definiert als

$$H = \frac{\sum_{S=1}^{n} N \times f_S \times ld\left(\frac{1}{f_S}\right)}{N} = \sum_{S=1}^{n} f_S \times ld\left(\frac{1}{f_S}\right)$$ Shannons Formel

  - E.g. $H_{aaaabbcd} = \frac{14}{8} = 1.75\,bit$
  - H hängt ausschließlich von der Anzahl und den relativen Häufigkeiten der Symbole ab

EINIGE GRUNDBEGRIFFE DER INFORMATIONSTHEORIE

ANWENDUNGSBEREICH

- Diese Konzepte und Maße der Informationstheorie lassen sich anwenden auf
  - Symbole, Zeichen, Silben, Wörter
  - (Musik-)Noten
  - Bilder
  - Soziale Gruppen, z. B. Anzahl der Stimmen pro Person
- Ein Frequenzschema ist eine einheitliche Darstellung solcher Nachrichten
  - „Nachricht“ ist der Oberbegriff für Text
  - Das gilt beispielsweise auch für Noten und Bilder

EINIGE GRUNDBEGRIFFE DER INFORMATIONSTHEORIE

FREQUENZSCHEMA

- Schritte zur Einrichtung eines Frequenzschemas
  1. Alle Symbole s einer Nachricht werden ermittelt
  2. Die relativen Häufigkeiten f aller Symbole werden berechnet
  3. Die Symbole und ihre relativen Häufigkeiten sind in absteigender Reihenfolge entsprechend ihrer relativen Häufigkeiten dargestellt.

$$\binom{s_1 s_2 \dots s_n}{f_1 f_2 \dots f_n}, given\ that \sum_{s=1}^{n} f_s = 1$$

  - Z. B. das Frequenzschema „aaaabbcd“
    - $\begin{pmatrix} a & b & c & d \\ \frac{1}{2} & \frac{1}{4} & \frac{1}{8} & \frac{1}{8} \end{pmatrix}$

EINIGE GRUNDBEGRIFFE DER INFORMATIONSTHEORIE

ENTROPIE

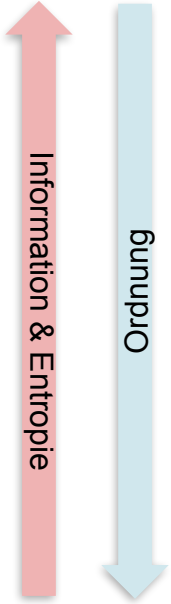
- Vorherige Messwerte können berechnet werden
  - Relative Häufigkeiten
  - Wahrscheinlichkeiten
- In der Informationstheorie ist Entropie ein Maß, das Unordnung quantifiziert
  - Sind alle Teile eines Systems, z. B. alle Symbole einer Nachricht, gleichmäßig verteilt oder weisen sie die gleiche Wahrscheinlichkeit auf, ist die Entropie maximal, d. h., es herrscht maximale Unordnung.
  - Um maximale Unordnung zu beschreiben, ist ein Informationsmaximum erforderlich

$$\begin{pmatrix} S_1 & S_2 & S_3 & S_4 \\ \frac{1}{4} & \frac{1}{4} & \frac{1}{4} & \frac{1}{4} \end{pmatrix}, H = 2.00\,bit$$

$$\begin{pmatrix} S_1 & S_2 & S_3 & S_4 \\ \frac{1}{2} & \frac{1}{4} & \frac{1}{8} & \frac{1}{8} \end{pmatrix}, H = 1.75\,bit$$

$$\begin{pmatrix} S_1 & S_2 & S_3 & S_4 \\ \frac{3}{4} & \frac{1}{8} & \frac{1}{8} & 0 \end{pmatrix}, H = 1.06\,bit$$

$$\begin{pmatrix} S_1 & S_2 & S_3 & S_4 \\ 1 & 0 & 0 & 0 \end{pmatrix}, H = 0.00\,bit$$



EINIGE GRUNDBEGRIFFE DER INFORMATIONSTHEORIE

REDUNDANZ

- H-Werte, die gemäß der Shannon-Formel berechnet wurden, dürfen nur zwischen Frequenzschemata mit derselben Symbolanzahl verglichen werden.
- Die Redundanz R normiert H auf den Bereich 0 ≤ R ≤ 1

$$R = 1 - \frac{H}{H_{max}} = 1 - \frac{H}{ld(N)} = \frac{H_{max} - H}{H_{max}}$$

  - E.g., $R_{aaabbcd} = 1 - \frac{1.75}{3} = 1 - 0.58 = 0.42$
  - R-Werte lassen sich zwischen beliebigen Frequenzschemata vergleichen
- Redundanz bedeutet Wiederholung oder Weitschweifigkeit
  - Aus psychologischer Sicht kann Redundanz beim Empfänger Langeweile hervorrufen.
  - Technisch gesehen ist eine Redundanz der Nachrichten erforderlich, um Störungen auszugleichen

INFORMATIONSTHEORIE

- Verlustfreie Komprimierung
  - Verfahren zur Datenkomprimierung ohne Informationsverlust
  - Die Originaldaten lassen sich vollständig aus den komprimierten Daten wiederherstellen.
- Verschlüsselung
  - Verschlüsselung und Entschlüsselung von Nachrichten mithilfe von Einzelschlüsseln oder öffentlichen/privaten Schlüsselpaaren
- Blockchain
  - Verteilte Datenbank mit kryptografisch verknüpftem Inhalt

FRAGEN?



UNIVERSITÄT
LEIPZIG

Dr. Nico Willert Stark
willert@wifa.uni-leipzig.de

Prof. Dr. Ulrich Eisenecker
Professur für Wirtschaftsinformatik, insbes. Softwareentwicklung
Für Wirtschaft und Verwaltung
Grimmaische Straße 12, 04109 Leipzig, Germany
T +49 341 97-33720 F +49 341 97-33729

eisenecker@wifa.uni-leipzig.de
Professur Softwareentwicklung für Wirtschaft und Verwaltung